RAPPORT DE SYNTHÈSE

Analyse théorique, formalisation mathématique et benchmarking expérimental sur données réelles

Auteurs : Équipe Master ML **Périmètre :** 29 Algorithmes (Supervisé, Non-Supervisé, RL) **Volume :** 6 Pages A4

1. INTRODUCTION ET OBJECTIFS DU PROJET

Ce rapport constitue la synthèse exhaustive d'un travail d'expérimentation et d'analyse théorique portant sur **29 algorithmes fondamentaux du Machine Learning et du Reinforcement Learning**. Ce projet vise à combler le fossé entre la formulation mathématique théorique et l'implémentation pratique sur des jeux de données réels.

L'étude s'articule autour de deux axes fondamentaux :

- **Partie A — Analyse Théorithique & Schématique :** Pour chaque algorithme, une analyse concise (8 à 12 lignes) comprenant sa famille, son intuition sous-jacente, ses équations fondamentales, ses avantages/limites, ses cas d'usage métiers (finance, logistique, marketing, gestion) et une évaluation de son code.
- **Partie B — Expérimentation Pratique & Benchmarking :** Validation empirique sur des jeux de données publics réels (UCI, OpenML, UN Comtrade, Gymnasium) en proscrivant les données synthétiques pour les métriques de validation finale.

2. MÉTHODOLOGIE D'EXPÉRIMENTATION SUR DONNÉES RÉELLES

Pour garantir la traçabilité et éviter toute fuite d'information (*data leakage*), une chaîne de traitement stricte a été déployée (Pedregosa et al., 2011) :

- **Prétraitement cloisonné :** L'imputation des valeurs manquantes, l'encodage et la normalisation (*StandardScaler*, *MinMaxScaler*) sont ajustés (*fit*) exclusivement sur l'ensemble d'entraînement, puis appliqués (*transform*) sur les jeux de validation et de test.
- **Découpage et Stratification :**
  - *Données Tabulaires Supervisées :* Séparation stratifiée Train / Validation / Test (70 / 15 / 15) pour maintenir la proportion exacte des classes.
  - *Séries Temporelles :* Validation chronologique glissante (*Time-Series Split*) respectant rigoureusement la causalité temporelle.
  - *Apprentissage par Renforcement :* Évaluation sur des environnements standardisés (Gymnasium) avec répétitions sur 10 graines aléatoires (*random_state=42*) (Sutton & Barto, 2018).

3. ANALYSE THÉORIQUE DÉTAILLÉE DES ALGORITHMES (1 À 5 / 29)

1. Régression Linéaire (OLS)

Supervisé / Régression

Intuition & Équations : Ajuste une hyperplan minimisant la somme des carrés des résidus (RSS). $y = X\beta + \varepsilon$. La solution analytique est $\beta = (X^T X)^{-1} X^T y$.

Avantages / Limites : Modèle hautement interprétable et rapide. Très sensible aux valeurs aberrantes et à la multicolinéarité.

Cas d'usage : (1) Finance : Prévision économétrique des taux d'intérêt. (2) Logistique : Estimation des délais de livraison selon la distance.

2. Régression Ridge (L2)

Supervisé / Régression

Intuition & Équations : Ajoute une pénalité L2 à l'OLS pour réduire la variance des coefficients. Critère : $min\ ||y - X\beta||^2 + \lambda||\beta||_2^2$. Solution : $\beta = (X^TX + \lambda I)^{-1}X^Ty$.

Avantages / Limites : Gère parfaitement la multicolinéarité. Ne réalise pas de sélection de variables (coefficients réduits mais non nuls).

Cas d'usage : (1) Finance : Modélisation des rendements d'actifs avec facteurs corrélés. (2) Marketing : Attribution multi-touch.

3. Régression Lasso (L1)

Supervisé / Régression

Intuition & Équations : Ajoute une pénalité L1 provoquant la raréfaction des coefficients (sélection de variables). Critère : $min\ ||y - X\beta||^2 + \lambda||\beta||_1$.

Avantages / Limites : Élimine les variables non pertinentes. Peut être instable en cas de très fortes corrélations (en choisit une au hasard).

Cas d'usage : (1) Gestion : Scoring de risque avec identification des 5 facteurs clés. (2) Santé : Sélection d'indicateurs biologiques.

4. ElasticNet

Supervisé / Régression

Intuition & Équations : Combinaison convexe des pénalités L1 (Lasso) et L2 (Ridge). Critère : $min\ ||y - X\beta||^2 + \lambda_1||\beta||_1 + \lambda_2||\beta||_2^2$.

Avantages / Limites : Allie sélection de variables et gestion du groupement de variables corrélées. Nécessite le réglage de deux hyperparamètres.

Cas d'usage : (1) Finance : Modélisation du risque systémique bancaire. (2) Logistique : Prévision de demande à forte dimensionnalité.

5. Régression Logistique

Supervisé / Classification

Intuition & Équations : Modélise la probabilité d'appartenance à une classe via la fonction sigmoïde : $P(y=1|x) = 1 / (1 + e^{-z})$ où $z = X\beta$. Optimisation par Maximisation de la Vraisemblance (Log-Loss).

Avantages / Limites : Sortie probabiliste directe, calcul très rapide. Ne capte pas naturellement les interactions non linéaires.

Cas d'usage : (1) Finance : Scoring d'accord de prêt bancaire. (2) Marketing : Prédiction de l'attrition client (Churn).

ANALYSE THÉORIQUE DÉTAILLÉE DES ALGORITHMES (6 À 11 / 29)

6. k-Nearest Neighbors (k-NN)

Supervisé / Classif. & Régression

Intuition & Équations : Modèle non paramétrique (« lazy »). Assigne la classe majoritaire des k plus proches voisins selon une distance (Euclidienne : $d(x,y) = \sqrt{(\sum(x_i - y_i)^2)}$ ou Manhattan).

Avantages / Limites : Simple, aucune hypothèse sur la distribution. Sensible au fléau de la dimensionnalité et coût de prédiction élevé en $O(n \cdot p)$.

Cas d'usage : (1) Marketing : Systèmes de recommandation e-commerce. (2) Immobilier : Estimation de biens par comparaison de voisinage.

7. Naive Bayes (Gaussian / Multinomial)

Supervisé / Classification

Intuition & Équations : Applique le théorème de Bayes en supposant l'indépendance conditionnelle des variables sachant la classe : $P(y|x) \propto P(y) \prod P(x_i|y)$.

Avantages / Limites : Extrêmement rapide, très efficace sur des données textuelles peu abondantes. L'hypothèse d'indépendance est souvent violée en pratique.

Cas d'usage : (1) Marketing : Analyse de sentiment de commentaires clients. (2) Gestion : Filtrage automatique de courriels (Spam).

8. Arbre de Décision (CART)

Supervisé / Classif. & Régression

Intuition & Équations : Segmente l'espace des descripteurs en régions orthogonales. Critères de séparation : Impureté de Gini $I_G = 1 - \sum p_i^2$ ou Entropie pour la classification ; Variance pour la régression.

Avantages / Limites : Règle de décision lisible sous forme d'arbre. Tendance majeure au surapprentissage (overfitting) sans élagage.

Cas d'usage : (1) Gestion : Arbre de décision d'octroi de crédit. (2) Santé : Arbres de diagnostic clinique rapide.

9. Random Forest

Supervisé / Ensemble (Bagging)

Intuition & Équations : Combine M arbres de décision entraînés sur des sous-échantillons bootstrap avec sélection aléatoire d'un sous-ensemble de $m = \sqrt{p}$ variables à chaque nœud. Prédiction par vote majoritaire ou moyenne.

Avantages / Limites : Très performant, réduit la variance des arbres simples, fournit l'importance des variables. Moins interprétable qu'un arbre unique.

Cas d'usage : (1) Finance : Détection du risque de défaut d'entreprises. (2) Logistique : Prédiction des pannes d'équipement (Maintenance prédictive).

10. SVM Linéaire (Support Vector Machine)

Supervisé / Classif. & Régression

Intuition & Équations : Recherche l'hyperplan qui maximise la marge géométrique entre deux classes : $min\ (1/2)||w||^2 + C \sum \xi_i$ sous contraintes de séparation.

Avantages / Limites : Robuste en grande dimension (textes). Moins adapté si le problème présente des frontières fortement non linéaires.

Cas d'usage : (1) Finance : Classification binaire de solvabilité. (2) Marketing : Catégorisation de requêtes de recherche textuelles.

11. SVM Kernel (RBF)

Supervisé / Classif. & Régression

Intuition & Équations : Projette les données dans un espace de Hilbert de dimension infinie via l'astuce du noyau (Kernel Trick). Noyau RBF : $K(x,x') = exp(-\gamma\ ||x - x'||^2)$.

Avantages / Limites : Modélise des frontières de décision très complexes. Complexité temporelle en $O(n^2)$ à $O(n^3)$, rendant les grands datasets impraticables.

Cas d'usage : (1) Biologie : Reconnaissance de motifs génomiques. (2) Finance : Détection de régimes de marché complexes.

ANALYSE THÉORIQUE DÉTAILLÉE DES ALGORITHMES (12 À 17 / 29)

12. Gradient Boosting (XGBoost / LightGBM)

Supervisé / Ensemble (Boosting)

Intuition & Équations : Construit séquentiellement des arbres réduisant les résidus du modèle précédent par descente de gradient. $F_m(x) = F_{m-1}(x) + \gamma_m\ h_m(x)$ (Chen & Guestrin, 2016).

Avantages / Limites : Performance d'état de l'art sur données tabulaires. Nécessite un réglage rigoureux d'hyperparamètres pour éviter le surapprentissage.

Cas d'usage : (1) Finance : Détection de transactions frauduleuses par carte bancaire. (2) Marketing : Optimisation des enchères publicitaires.

13. Perceptron Multicouche (MLP / ANN)

Supervisé / Réseaux de Neurones

Intuition & Équations : Réseau de neurones à couches cachées calculant $a^{(l)} = \sigma(W^{(l)}a^{(l-1)} + b^{(l)})$. Optimisé par rétropropagation du gradient (Algorithme d'Adam / SGD).

Avantages / Limites : Approximateur universel de fonctions. Effet « boîte noire », temps d'entraînement long et besoin de grands volumes de données.

Cas d'usage : (1) Gestion : Tarification dynamique de billets ou nuitées. (2) Actuariat : Modélisation non linéaire de sinistralité.

14. K-Means

Non-Supervisé / Clustering

Intuition & Équations : Partitionne les observations en k clusters en minimisant l'inertie intra-classe : $arg\ min \sum \sum ||x - \mu_i||^2$ via une alternance d'affectations et de mise à jour des centroïdes.

Avantages / Limites : Simple, rapide et scalable. Sensible au choix de k et aux valeurs aberrantes ; suppose des clusters sphériques.

Cas d'usage : (1) Marketing : Segmentation de clientèle selon la méthode RFM (Récence, Fréquence, Montant). (2) Logistique : Regroupement de points de livraison.

15. Clustering Hiérarchique (AGNES)

Non-Supervisé / Clustering

Intuition & Équations : Stratégie agglomérative construisant un dendrogramme en fusionnant itérativement les deux clusters les plus proches selon une métrique (Ward, Single, Complete linkage).

Avantages / Limites : Ne requiert pas de fixer k a priori, fournit une hiérarchie visuelle. Complexité temporelle prohibitive en $O(n^3)$ ou $O(n^2 \log n)$.

Cas d'usage : (1) Gestion : Typologie stratégique de marchés internationaux. (2) Bio-informatique : Classification d'espèces ou gènes.

16. DBSCAN

Non-Supervisé / Clustering basé densité

Intuition & Équations : Regroupe les points situés dans des zones de forte densité (au moins *MinPts* dans un rayon ε) et isole les points de faible densité comme du bruit.

Avantages / Limites : Détecte des formes géométriques arbitraires et isole le bruit. Difficultés sur des jeux de données avec des densités variables.

Cas d me : (1) Logistique : Identification des zones urbaines de forte congestion. (2) Sécurité : Détection d'anomalies de trafic réseau.

17. Gaussian Mixture Models (GMM)

Non-Supervisé / Clustering Probabiliste

Intuition & Équations : Suppose que les données sont générées par un mélange de K distributions gaussiennes. Optimisé par l'algorithme EM (Expectation-Maximization) pour estimer π_k, μ_k, Σ_k.

Avantages / Limites : Clustering souple (soft assignment) avec matrices de covariance flexibles. Risque de convergence vers des optima locaux.

Cas d'usage : (1) Finance : Modélisation des profils d'investisseurs avec chevauchement. (2) Traitement de signal : Séparation de sources audio.

ANALYSE THÉORIQUE DÉTAILLÉE DES ALGORITHMES (18 À 23 / 29)

18. Analyse en Composantes Principales (ACP / PCA)

Non-Supervisé / Réduction de Dimension

Intuition & Équations : Projette les données sur des axes orthogonaux maximisant la variance expliquée. Calculé via la décomposition en valeurs singulières (SVD) de la matrice de covariance : $X^T X = V \Sigma^2 V^T$.

Avantages / Limites : Élimine la colinéarité et réduit la dimension sans perte d'information linéaire majeure. Ne capte pas les structures non linéaires.

Cas d'usage : (1) Finance : Construction d'indices synthétiques de santé financière. (2) Image : Compression d'images (Eigenfaces).

19. t-SNE

Non-Supervisé / Visualisation Non-Linéaire

Intuition & Équations : Convertit les distances euclidiennes en probabilités de similitude (gaussiennes en haute dimension, Student-t en basse dimension) et minimise la divergence KL : $KL(P||Q) = \sum p_{ij} \log(p_{ij} / q_{ij})$.

Avantages / Limites : Visualisation exceptionnelle de clusters complexes en 2D/3D. Ne préserve pas les distances globales ; coûteux en temps.

Cas d'usage : (1) Marketing : Cartographie visuelle de la proximité des produits dans le catalogue. (2) Biologie : Visualisation de cellules uniques (scRNA-seq).

20. UMAP

Non-Supervisé / Réduction de Dimension

Intuition & Équations : Repose sur la géométrie riemannienne et la topologie algébrique. Recherche une représentation en basse dimension maximisant l'entropie croisée des flous topologiques (McInnes et al., 2018).

Avantages / Limites : Plus rapide que t-SNE et préserve mieux la structure globale. Moins d'interprétabilité mathématique directe.

Cas d'usage : (1) Finance : Projection d'un grand nombre d'indicateurs boursiers. (2) NLP : Réduction de dimension d'embeddings de texte.

21. Isolation Forest

Détection d'Anomalies

Intuition & Équations : Isole les anomalies en tirant au hasard des caractéristiques et des seuils de coupure. Les anomalies sont isolées plus rapidement (profondeur d'arbre $h(x)$ plus courte que la moyenne $c(n)$).

Avantages / Limites : Très efficace sur de très grands jeux de données multidimensionnels en $O(n \log n)$. Peut créer des artefacts dans les espaces peu denses.

Cas d'usage : (1) Finance : Détection d'anomalies dans le flux de paiements SWIFT. (2) Industrie : Détection d'anomalies de capteurs de production.

22. One-Class SVM

Détection d'Anomalies / Nouveauté

Intuition & Équations : Apprend un hyperplan ou une frontière minimale (via noyau RBF) englobant la majorité des données normales et séparant l'origine du reste de l'espace.

Avantages / Limites : Très efficace pour la détection de nouveautés sans exemples d'anomalies. Sensible au choix des hyperparamètres ν et γ.

Cas d'usage : (1) Sécurité : Détection d'intrusions informatiques inédites (Zero-day). (2) Assurance : Détection de sinistres suspects rares.

23. Local Outlier Factor (LOF)

Détection d'Anomalies

Intuition & Équations : Compare la densité locale d'un point à celle de ses k plus proches voisins. Un score LOF nettement supérieur à 1 indique un point situé dans une zone de densité inférieure.

Avantages / Limites : Capte des anomalies locales dans des datasets à densités différentes. Complexité temporelle en $O(n^2)$.

Cas d'usage : (1) Logistique : Contrôle d'anomalies de livraison dans les tournées. (2) Santé : Détection de constantes vitales déviantes.

ANALYSE THÉORIQUE DÉTAILLÉE DES ALGORITHMES (24 À 29 / 29)

24. Bandit Multi-bras (ε-Greedy)

Apprentissage par Renforcement

Intuition & Équations : Arbitre entre l'exploitation du meilleur bras actuel (probabilité $1 - \varepsilon$) et l'exploration aléatoire des autres bras (probabilité ε) pour maximiser la récompense cumulée.

Avantages / Limites : Stratégie simplifiée très intuitive. L'exploration reste constante même lorsque les estimations deviennent fiables.

Cas d'usage : (1) Marketing : Optimisation en temps réel d'affichages d'offres promotionnelles (A/B testing dynamique). (2) Santé : Essais cliniques adaptatifs.

25. Bandit UCB (Upper Confidence Bound)

Apprentissage par Renforcement

Intuition & Équations : Sélectionne l'action maximisant la borne supérieure d'un intervalle de confiance : $A_t = arg\ max\ [Q(a) + c \sqrt{(ln\ t / N_t(a))}\ ]$. Favorise les actions peu explorées.

Avantages / Limites : Garanties théoriques de regret logarithmique optimal. Suppose des récompenses stationnaires.

Cas d'usage : (1) Marketing : Recommandation de contenus d'actualité en continu. (2) Finance : Allocation dynamique de capital entre opportunités.

26. Q-Learning (Off-Policy)

Apprentissage par Renforcement Tabulaire

Intuition & Équations : Met à jour la Q-table de manière indépendante de la politique suivie : $Q(s,a) \leftarrow Q(s,a) + \alpha\ [\ r + \gamma\ max\ Q(s',a') - Q(s,a)\ ]$.

Avantages / Limites : Converge vers la politique optimale. Limité aux espaces d'états et d'actions discrets et de petite taille.

Cas d'usage : (1) Logistique : Routage et optimisation de trajectoires de robots d'entrepôt. (2) Jeux : Résolution d'environnements discrets (*FrozenLake*).

27. SARSA (On-Policy)

Apprentissage par Renforcement Tabulaire

Intuition & Équations : Met à jour la valeur Q en fonction de la transition réelle exécutée par la politique : $Q(s,a) \leftarrow Q(s,a) + \alpha\,[\,r + \gamma\,Q(s',a') - Q(s,a)\,]$.

Avantages / Limites : Plus prudent que le Q-learning car prend en compte les risques d'exploration. Convergence plus lente.

Cas d'usage : (1) Gestion : Contrôle de processus industriels à contraintes de sécurité strictes. (2) Conduite autonome : Pilotage prudent.

28. Deep Q-Network (DQN)

Deep Reinforcement Learning

Intuition & Équations : Remplace la Q-table par un réseau de neurones approximateur $Q(s,a;\,\theta)$. Utilise la mémoire de rejeu (Experience Replay) et un réseau cible (Target Network) pour stabiliser l'apprentissage.

Avantages / Limites : S'attaque à des espaces d'états continus complexes. Instabilité de l'entraînement et coût en ressources calculatoires.

Cas d'usage : (1) Finance : Trading algorithmique à haute fréquence. (2) Robotique : Contrôle d'articulations d'un bras robotisé (*CartPole*).

29. Réseau Convolutif (CNN)*

Deep Learning / Vision

Intuition & Équations : Applique des filtres de convolution spatiale réduisant le nombre de paramètres et extrayant des caractéristiques hiérarchiques : $S(i,j) = (I * K)(i,j)$ suivi de Pooling.

Avantages / Limites : Invariance par translation, performances exceptionnelles sur données spatiales. Nécessite de grands volumes d'images annotées.

Cas d'usage : (1) Logistique : Inspection automatique par vision de l'état des colis. (2) Distribution : Caisses automatiques sans scan.

4. TABLEAU COMPARATIF SYNTHÉTIQUE DES PERFORMANCE & COMPLEXITÉ

N°	Algorithme	Famille	Métriques	Interprétabilité	Complexité Entraînement	Cas d'Usage Privilégié
1-4	**Régression Linéaire, Ridge, Lasso, ElasticNet**	Régression Supervisée	MAE, RMSE, R^2	Élevée à Très Élevée	$O(p^2n + p^3)$	Prévision ventes, scoring économétrique, risque bancaire
5	**Régression Logistique**	Classification	F1, ROC-AUC	Élevée	$O(n \cdot p)$	Scoring d'octroi de prêt, attrition client (Churn)
6-7	**k-NN, Naive Bayes**	Supervisé Simple	F1, Accuracy	Élevée	$O(1)$ à $O(n \cdot p)$	Filtrage spam, analyse de sentiment, recommandation
8-9	**Decision Tree, Random Forest**	Arbres / Bagging	F1, ROC-AUC	Moyenne à Élevée	$O(M \cdot p \cdot n \log n)$	Scoring risque de défaut, maintenance prédictive
10-11	**SVM (Linéaire & RBF)**	Supervisé / Kernels	F1, ROC-AUC	Moyenne à Faible	$O(n \cdot p)$ à $O(n^3)$	Classification binaire stricte, détection de motifs
12-13	**Gradient Boosting (XGBoost), MLP**	Boosting / Neurones	F1, PR-AUC, MSE	Faible à Moyenne	Élevée (GPU/CPU)	Détection de fraude carte, pricing dynamique
14-17	**K-Means, AGNES, DBSCAN, GMM**	Clustering	Silhouette, BIC	Moyenne à Élevée	$O(k{\cdot}n{\cdot}p)$ à $O(n^3)$	Segmentation RFM, typologie marché, zones logistiques
18-20	**ACP, t-SNE, UMAP**	Réduction Dim.	Var. Expl. / KL	Moyenne à Faible	$O(p^2n)$ à $O(n \log n)$	Compression macroéconomique, visual. catalogues HD
21-23	**Isolation Forest, One-Class SVM, LOF**	Anomalies	Precision@K, AUC	Moyenne à Faible	$O(M{\cdot}n \log n)$ à $O(n^2)$	Détection de fraudes SWIFT, intrusions réseau

N°	Algorithme	Famille	Métriques	Interprétabilité	Complexité Entraînement	Cas d'Usage Privilégié
24-28	**Bandits, Q-Learning, SARSA, DQN**	Renforcement (RL)	Récompense Cumulée	Moyenne à Faible	O(1) à Élevée (GPU)	A/B Testing dynamique, routage logistique, trading
29	**CNN (Vision)***	Deep Learning	Accuracy, Loss	Faible	Très Élevée (GPU)	Contrôle qualité automatique en chaîne logistique

5. DISCUSSION, LIMITES ET RECOMMANDATIONS PRATIQUES

1. **Arbitrage Interprétabilité vs Performance :** Dans les secteurs réglementés (banque, assurance, santé), la Régression Logistique ou Lasso prévalent. L'implémentation de modules **SHAP (SHapley Additive exPlanations)** s'impose comme standard pour expliquer les modèles complexes (XGBoost, Random Forest).
2. **Passage à l'Échelle (Scalabilité) :** Éviter les algorithmes à complexité super-linéaire ($O(n^2)$ ou plus comme SVM Kernel, LOF, Clustering Hiérarchique) sur des jeux de données dépassant 100 000 lignes. Privilégier des déclinaisons linéarisées ou XGBoost.
3. **Reproductibilité :** Toujours verrouiller l'ensemble des générateurs pseudo-aléatoires avec la graine fixe (*random_state = 42*).